



Computermind

---

# Development Stories

## 開発事例集 ～ 研究開発・Poc編 ～


---

当社R&D・顧客からのPoCなど様々な形態で日々研究開発を行っております。  
主に、AI、機械学習、GPGPU、点群データなど、日進月歩の最新技術を使用し  
開発を行っております。



## AI関連

半教師あり学習による物体検出ソフトウェア試作開発	P3
AIを用いた物理方程式解析	P4
GANの技術調査	P5
充足性判定に向けたニューロンカバレッジの実装評価	P6
破面起点解析	P7
深層学習バイナリモデルのエッジデバイス実装評価	P8
外観検査における異常検知手法 山梨大学との共同研究	P9
少量データにおける不良判定学習手法の検証	P10
説明可能AI	P11




## GPGPU

FISH-QUANT CUDA開発	P13
X線CT画像3D復元高速化	P14



## SLAM

点群データ関連最新技術の調査・実装	P16
ドローン制御用自己位置推定モジュール	P17



## ロボティクス

アームロボットを使用した強化学習	P19
ロボット制御支援	P20



## データ分析

半導体製造装置 データ解析モジュール開発	P22
半導体製造装置 計測箇所最適化	P23
マテリアルズインフォマティクス	P24



## 画像処理

電顕3次元再構築	P26
----------	-----

---

# AI

## ～ artificial intelligence ～

2012年のILSVRCをきっかけに、第3次AIブームが始まっています。

当社でもいち早くDeepLearningに着目し、これまでに様々な製品、システムを開発してきました。

# 半教師あり学習による物体検出ソフトウェア試作開発

DeepLearningが広まっていくことで、知見がない部門の方たちにも導入を検討してもらう為に、DeepLearningを試すことが出来るアプリケーションの需要が高まっています。

そこで、操作方法がシンプルで分かりやすい画面を持った学習アプリケーションを開発することで、様々な方が簡単な説明で操作できるようになり、独自のデータを用いて学習を行いDeepLearningの導入が有効であるかの判断が素早くできるような仕組みを作りました。

また、本開発では、学習用にGPUサーバーを使用し、複数の学習インスタンスを立て、無駄なくGPUが稼働出来るようにクライアントサーバシステムを使用しました。

また、環境を選ばず利用できるようにウェブブラウザで表示することで、様々なユーザが自由に学習を行うことが出来るようになりました。

## 半教師あり学習の自動化

### 教師あり学習



### 半教師あり学習



本アプリケーションの大きな特徴として、一般的な教師あり学習だけでなく半教師あり学習にも対応している点があります。

簡単な検証で行う際に、ラベルが付いた学習データを大量に用意することはなかなか難しいことだと思います。

そこで、少量のラベル付きデータを用意して学習し、ラベル付与用の学習済みモデルを用意します。その後、これまでに蓄積していた大量の画像データに対して学習済みモデルを用いて推定ラベルを付けることで、大量のラベル付き学習データセットが用意できます。これを用いて再度学習することで、高精度なモデルを生成することが可能となります。

上記のような手順を独自に行おうとすると、ある程度知見が無いと実行することが出来ません。

そこで、本アプリケーションでは、必要なデータセットをセットして、モデルを指定するだけで、ラベル付けから再学習まで全て自動で実行するシステムを構築しています。

これにより、煩雑な作業を最小限にして、検証において十分な精度のモデルが生成できる為、DeepLearningの検証の機会が増えて、導入までのハードルを下げる事が出来ます。


### 開発例

項目	詳細情報
OS	Ubuntu
開発期間	6ヶ月
開発人数	3人
開発言語	Python
対応ネットワーク	SSD YOLO
GPU	開発：GeForce TITAN X 動作：GeForce TITAN X
関連技術	DeepLearning Docker、ZeroMQ Flask CSS、HTML WinSCP

# AIを用いた物理方程式解析

物理現象を分析し、将来の状態を予測する手段として、物理理論に基づいて立式された物理方程式を解くことが現在の主流となっています。

しかし、一般に物理方程式を解くためには高度な知識と技術が必要であり、その専門性をAIの利用で解消する研究が注目を集めています。



本開発では、そのような最新の研究を対象として、論文を元に実装して性能評価を行っています。

そこで発覚した問題点については、AI・物理・数学といった関連分野での多角的な視点で原因を分析し、問題を解決する改良手法を考案してその効果を実証しました。

また、この手法の構造と特性を観察し、物理現象の解析に限らない広い分野に応用する実験も行っており、現在は統計的推定の問題をDeepLearningによって解く研究を進めています。

## 最新手法の調査と改良

論文で発表される最新の手法は、いずれも従来手法の問題を解決し得るものですが、現実の問題に適用するためには、その性質を明らかにして問題点を洗い出し、改良を加える必要があります。

そのため、論文で述べられた手法を実装するだけでなく、解析対象となる物理理論、手法の拠り所となるAIの理論、そして、多様な理論の共通言語である数学の理論に基づいて手法を分析し、いくつかの改良手法を考案しました。

それらの手法によって、対応する問題が解決することも実証しており、理論に基づく分析とデータに基づくAI処理の融合が効果的であることを示しています。

### 開発例

項目	詳細情報
OS	Windows
開発期間	2年～
開発人数	1人
開発言語	Python、Matlab
使用ネットワーク	MLPをベースにした独自ネットワーク
関連技術	DeepLearning Tensorflow (low-level API) 偏微分方程式 統計的推定

## GANの技術調査


スーパーマーケット等への導入を目的とした製品画像の学習データ生成を、GAN（敵対的生成ネットワーク）を用いて技術研究しました。

小売店には連日新しいパッケージを持つ製品が入荷しており、都度、学習モデルをアップデートしていくことは現実的ではありません。

そのため、パッケージとして現れる可能性を持つ学習データを、GANで生成することにより、未知のパッケージの物体検知を行うことができます。

## GANを利用したデータ拡張

当社では、近年様々な場面で利用されているGANを、DeepLearningの訓練データの拡張に利用しています。




GANを利用した合成画像の作成による訓練データ拡張の一例を以下に示します。

この検証では、Food-101 dataset[1]のpancakesクラスの画像に類似した画像を作成するために、GANを使用しています。[1] [https://www.vision.ee.ethz.ch/datasets\\_extra/food-101/](https://www.vision.ee.ethz.ch/datasets_extra/food-101/)

作成したGANモデルは、お皿の画像を入力するとpancakesに変換するように学習を行っています。

また、見た目は実画像と似ている合成画像ですが、実画像とはデータの分布が異なることが多く、合成画像のみを訓練データとして学習されたモデルは、合成データに対しては高い推論性能を示しますが、実データに対しては性能が低下してしまいます。

この問題を解決するために、コンピュータマインドでは合成画像を実画像のように変換してから、モデルの学習を行うGANの研究・利用をしています。



### 開発例

項目	詳細情報
OS	LUbuntu 16.04 LTS
開発期間	3ヶ月
開発人数	1人
開発言語	Python
使用ネットワーク	CycleGAN
GPU	GTX 1080Ti
関連技術	OpenCV



# 充足性判定に向けたニューロンカバレッジの実装評価

Deep Learningシステムの開発フローにおいて、質の良いデータが十分に準備されていることは良いモデルを生成するために非常に重要です。

当社では、データが十分に準備されているかを評価する指標として、ニューロンカバレッジあるいはその派生形が有効であるかを判定するための実装評価を行いました。結果として、評価したどの指標もデータが充分であることを判定する可能性を示すことができました。

データ充足性というテーマは世界的に発展途上であるため、今後もし取り上げられるであろう興味深いテーマです。

## ニューロンカバレッジとデータ充足性の関係

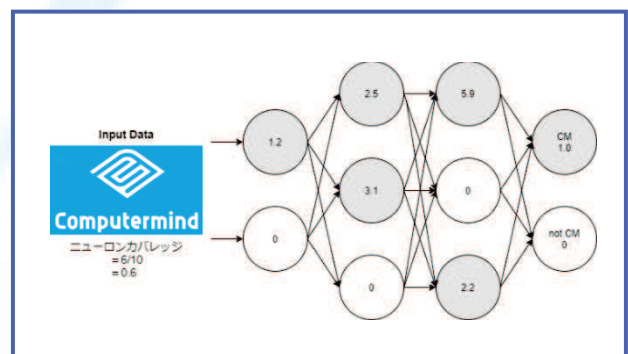
ニューロンカバレッジはモデルのニューロンの発火状況を数値化した指標です。

様々なデータが存在することにより多くのニューロンが発火する経験を得るという前提のもと、ニューロンカバレッジが大きいとデータが充分であると言えるだろうと推測されます。

この仮説を検証するために、質の良いオリジナルのデータセットに対し一律に変換を加えた質の悪いデータセットを準備しました。

準備した質の悪いデータセットに対してニューロンカバレッジを評価すると、オリジナルの質の良いデータセットで評価した際の数値より減少傾向にあることが確認されました。

今回の調査では傾向がみられることの確認に留まりましたが、ニューロンカバレッジのデータ充足性判定への適用可能性を示すことができました。



オリジナル データ破損 ノイズ付与 ぼかし

### 開発例

項目	詳細情報
OS	Windows
開発期間	1年
開発人数	1人
開発言語	Python
関連技術	DeepLearning Data Augmentation Adversarial attack

## 破面起点解析


ある工業製品における部材の破損状況の把握をこれまで有識者による目視で行っていました。破損の原因ごとに破損の起点となった部分を推定するタスクとなりますが、破損した部材の撮影画像から機械学習の手法で解析するモデルを作成します。そのプロセスとして以下の2つについてPoCの実施しました。

- 破損の起点位置をXY座標で推定する。
- 破損の起点位置を画像中心からの方向（角度）で推定する。
- 破損の状況（ひびなど）を模式図として出力し、有識者でなくても目視による判定を容易にする。

また本アプローチのモデル作成・テスト評価をエンドユーザー様のほうでも行っていただけるよう、その機能を有したGUIアプリケーションの開発も行っています。

## 深層学習による画像を入力とした回帰モデルの仕様

画像から抽出した特徴量をベースに分類モデルを作るというアプローチはDeepLearningモデルでは多く使われますが、本プロジェクトでは画像から抽出した特徴量から座標や角度を推定するという珍しいアプローチを用いました。



また模式図作成にはGANを用いた画像生成モデルであるpix2pixを用いています。



### 開発例

項目	詳細情報
OS	Windows 10 Pro
開発期間	3ヶ月
開発規模	PoC 1人 / 本開発1人
開発言語	Python, TypeScript
使用ネットワーク	VGG16ベース回帰モデル pix2pix
GPU	GeForce 3070
学習データ数	1課題につき50程度
関連技術	

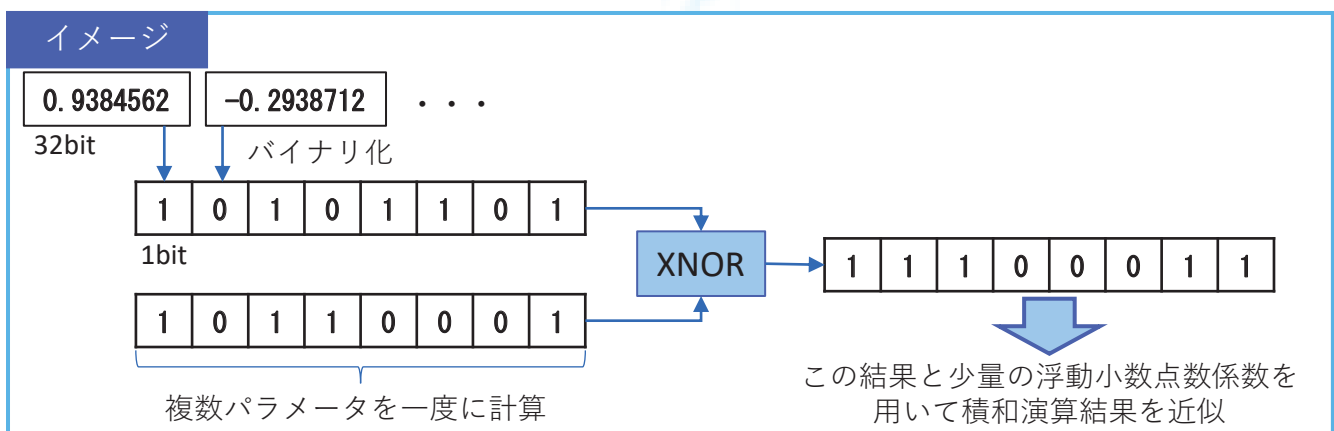


# 深層学習バイナリモデルのエッジデバイス実装評価

AIというと高性能なマシンでの運用が必要なイメージがありますが、近年で開発の進む自動運転やIoTデバイスなどのように、より現場に近いデバイスに実装しAIによる判断を行うことへのニーズが高まっています。学習自体は高性能なマシンで行いAIによる判断は小型で軽量のデバイスで行う、エッジデバイスへのDeepLearning実装に取り組んでまいりました。エッジデバイスの場合は小型・軽量ゆえに搭載メモリや処理速度の面で制限があり、推論処理を行う際には省メモリ化と高速化が課題となります。より少ないビット数で深層学習のパラメータを近似する量子化技術の中でも、計算量の多い畳み込み演算部分の入力・重みをバイナリ (1 bit) とし、わずかな浮動小数点型(32bit)の係数で積和演算結果を近似することで省メモリかつ高速に推論を行える XNOR-Net に着目し実装と検証を行いました。

## バイナリ化のメリット

- パラメータを浮動小数点型(32bit)からバイナリ(1bit)化することでメモリ容量と回路面積を削減
- 浮動小数点型(32bit)での積和演算を並列のビット演算にして高速に  
…大量に発生する積和演算処理で時間がかかる浮動小数点型の乗算の一部を、ビット演算（加算とビット単位の否定排他的論理和 [XNOR]）に置き換えることで処理の高速化が期待できます。



## バイナリモデルの適用先

XNOR-Netをはじめとするバイナリモデルを適用させることでエッジデバイス (FPGA) での推論の高速化と、計算時に確保するメモリ削減が期待できます。またバイナリ化の効果が表れるのはエッジデバイスだけではなく、PCのCPU環境であればSIMD命令を使うことで同様のモデルを実装することも可能です。NVIDIA社製のGPU環境であればTensorCoreを用いたバイナリ演算の高速化など、様々な用途への適用も考えられます。


### 開発例

項目	詳細情報
OS	Ubuntu
開発期間	6ヶ月
開発人数	1人
開発言語	Python、C
対応ネットワーク	AlexNet 独自作成のCNN
エッジデバイス (FPGA)	Ultra96v2
関連技術	DeepLearning、Vivado、 FINN、Brevitas、 TensorCore

# 外観検査における異常検知手法 山梨大学との共同研究

外観検査は製造業を中心に様々な業界で品質を保つために必要な工程としてあります。従来の異常検知では、画像処理などを用いてルールベースで行ってありますが、その方法では未知の異常は検知出来ない為、新たな異常パターンが発生しても見落としてしまう可能性があります。そのような中、未知の異常パターンであっても検知できるとして数年前よりDeepLearningを用いた異常検知に注目が集まり、様々な検知アルゴリズムが提案されてきました。

弊社ではこれらの技術のキャッチアップを行うべく、山梨大学安藤教授との共同研究でDeepLearningを用いた異常検知手法について比較検証を実施しました。



## 異常検知の最新手法を比較検証

DeepLearningを用いた異常が注目されるきっかけとなった手法から、昨今注目されている最新手法までを網羅的に評価し、手法ごとの精度や判定の傾向について一般公開されているMVTecAD<sup>※1</sup>データセットを利用して比較検証しました。

また、お客様が持っている画像データセットを用いて検証を行うことが出来るように検証環境を整えており、簡単にPoCに取り組むことが可能となっております。

### ・ 検証を行った手法一覧

- f-AnoGAN: Fast unsupervised anomaly detection with generative adversarial networks
- EFFICIENT GAN-BASED ANOMALY DETECTION
- CutPaste : Self Supervised Learning for Anomaly Detection and Localization
- Modeling the Distribution of Normal Data in Pre Trained Deep Features for Anomaly Detection
- Towards Total Recall in Industrial Anomaly Detection

今後は既存手法をベースにして、実際にお客様が持っているデータに対して高精度になるような特定のドメインに特化した異常検知手法の開発などを共同研究を通して進めていきます。



※1 P. Bergmann, M. Fauser, D. Sattlegger, and C. Steger, "Mvtect ad—a comprehensive real-world dataset for unsupervised anomaly detection," in CVPR, 2019.

### 開発例

項目	詳細情報
OS	Ubuntu 18.04 LTS
開発期間	2021年10月～継続
開発規模	大学3名 CM7名
開発言語	Python
使用ネットワーク	f-AnoGAN EfficientGAN GaussianAD CutPaste PatchCore
GPU	Tesla T4 (AWS g4dn.2xlarge)
学習データ数	6642枚 (15クラス)
関連技術	・ 深層学習 ・ 異常検知

## 少量データにおける不良判定学習手法の検証

ある検査機器メーカーがインフラ設備の点検を自動化する為に、物体検出モデルを用いて開発を行っていましたが、特定の欠陥の発生頻度が小さく中々データが集まらないこともあり、検出出来ても分類を誤判定してしまうという課題を抱えていました。そこで、分類タスクの精度改善を目的として、少量データでも学習可能な手法を使うことでどの程度精度を出すことが可能なのか検証を行いました。

元々、物体検出モデルにて検出と分類を行っていましたが、検出部分の性能は十分であることを考慮し、検出と分類のタスクを別で行うように処理を分割して、分類タスクの手法を変えてどの手法が有効であるか比較しました。



## 様々な少量データ学習手法の比較評価

少量データでの学習手法として、「距離学習(Metric Learning)」や「メタ学習(Meta Learning)」と呼ばれる学習手法の下記モデルを実装し、精度検証を行いました。

Deep metric learning using Triplet network

ArcFace: Additive Angular Margin Loss for Deep Face Recognition

MagFace: A Universal Representation for Face Recognition and Quality Assessment

On First-Order Meta-Learning Algorithms

コンピュータマインドでは、お客様の抱える課題に合わせて論文等を調査し、有効な手法をピックアップして、幾つかの手法を実際に実装・検証し、実用化に向けて有効であるかどうかを評価するPoCも行っています。




### 開発例


項目	詳細情報
OS	Windows 10 Pro
開発期間	6ヶ月
開発規模	2名
開発言語	Python
使用ネットワーク	TripletNetwork FaceNet MAML
GPU	Tesla T4 (AWS g4dn.2xlarge)
学習データ数	約2500枚
関連技術	深層学習 距離学習 メタ学習

## 説明可能AI

DeepLearningを始めとするAI技術の発展により、大規模なデータに対して単純なルールベースの手法では実現できない複雑な判断を自動で行えるようになりました。しかし、それに伴って予測アルゴリズムも複雑化しており、単にその手続きを追うだけでは「何故AIがそう判断したのか」という判断結果の説明が困難になっています。




この問題に対して、AIの予測アルゴリズムから人間に解釈可能な情報を抽出する説明可能AIの技術が研究されており、AIの判断に説明性を持たせる試みが盛んになされています。



## AIの説明結果についての説明の必要性

説明可能AI技術はAIモデルが持つ数理的な性質を抽出するもので、「説明可能AIが何を説明しているか」については人間が妥当な解釈を考える必要があります。



当社は説明可能AIのアルゴリズム解析も行い、当該技術がどのような説明を行っているかの解釈、及びに必要な説明を得るためにアルゴリズムを改良する調査・研究開発を行っています。

### 開発例

項目	詳細情報
OS	Windows
開発期間	1年～
開発人数	1人
開発言語	Python
関連技術	DeepLearning GradCAM



# GPGPU

～ General-purpose computing on graphics processing units ～

AI（DeepLearning）で使用されているGPUですが、豊富なコア数を有効活用して、演算処理の高速化が可能です。

GPUを効率よく使用するためには専用言語《CUDA》で実装する必要があります。

当社では、いち早くGPUによる高速化の優位性を見出し、案件を成功させて来ました。


# FISH-QUANT CUDA開発

FISH-QUANTと呼ばれるTranscripts(DNA塩基配列)をカウントするアルゴリズムがMATLABで実装されていたながら、

- ・処理時間が過分に掛かっている
- ・MATLABのライセンスを持っていないと利用することが出来ない

という点で有用でありながら使いづらい問題がありました。

そこで、C++/CUDAで解析処理部を実装し、C#で画面を実装することで、MATLABを使わずにFISH-QUANTが利用でき、従来のアプリケーションよりも高速に解析ができるようにしました。




## C++/CUDAに置き換えることで7倍の高速化

三次元フィッティングを行っている箇所をC++化して、処理が重くなっているフィッティング処理をCUDAで並列化しました。

MATLAB上では、処理時間が10時間掛かっていましたが、C++/CUDAで処理を置き換えたことで7倍の高速化を達成し、1.4時間で処理を完了させることが出来るようになりました。

また、処理の置き換えによる計算誤差についても検証を行い、90%近くの輝点がオリジナルと同等かそれ以上の精度であることを確認しました。

処理時間比較 (時間)



### 開発例

項目	詳細情報
OS	Windows
開発期間	3ヶ月
開発人数	1人
開発言語	C++、CUDA、C#
GPU	開発：Quadro M6000 動作：Tesla V100
関連技術	MATLAB 3D Gauss Fitting




# X線CT画像3D復元高速化

レントゲン撮影は1方向からX線を照射し、被写体内部の2次元写真を撮影します。  
X線CTスキャナでは360° 全方向からX線を被写体に照射し、数百～数千枚の2次元投影画像を取得します。

取得した投影画像を再構成(コンピュータ処理)し、3次元画像(2次元輪切り画像の積み重ね)を生成します。

X線CT画像の再構成には非常に時間がかかる上に、画質を良くするために補正処理を繰り返し行う必要があります。



実際のシステムに載る前のプロトタイプ開発として、GPGPUという技術を用いて時間のかかる再構成～補正処理の高速化を実現しました。


## CUDA/C++ による高速化

X線CT画像を3次元復元するための再構成～補正処理の内、処理の重くなっている箇所をCUDAで並列処理することで処理を高速化しました。

再構成処理単体で約43倍の高速化を実現し、処理全体で約20倍の高速化(例：30分→1.5分)を実現しました。

実運用では大量にメモリを使用する処理のため、データフローについての調査と対処方法の検討まで含めて報告しました。

### 開発例



項目	詳細情報
OS	Win 10 Pro
開発期間	2カ月
開発人数	2人
開発言語	CUDA/C++ (VS2015 pro)
CUDA	9.2
GPU	開発：GTX 1080Ti 動作：GTX 1080Ti
関連技術	GPGPU

# SLAM

## ～ Simultaneous Localization and Mapping ～

近年、AIに並び注目されているのがSLAM(Simultaneous Localization and Mapping)です。

自動運転やロボット掃除などに徐々に実製品に組み込まれて来っており、非常に注目されている技術の一つです。

SLAMに関する開発にも積極的に取り組み、将来的にAI+SLAMの更に高度なソリューション提供を目指しております。

## 点群データ関連最新技術の調査・実装

現実世界の対象物を3次元カメラ等で撮影し取得した点群データを元に、地形や構造物、生き物の3Dポリゴンメッシュの高解像度化や修復等を行う様々な3次元処理の手法を研究してきました。

点群データは主に建築や自動運転の分野で広く取り扱われていますが、他にも点群ベースの姿勢解析アルゴリズムや、セキュリティ、外観検査への適用など、その用途は多岐に渡ります。




また、近年では点群データを対象とした深層学習モデルにも多数のアプローチが存在しているため、それらによって点群データの分類やセグメンテーションを行うためのより良い手法が常に議論され続けています。

## 論文解析から実装、改良までを広く対応 製品開発のための技術課題を解決

ソフトウェア、ハードウェア製品開発のための3次元点群処理のトレンドを追い、またその性能評価を行うことで、実用レベルでの手法の検討を行ってきました。

その他にも、複数視点の点群データを統合することによる高解像度な3Dオブジェクトの構築や3Dアニメーションに代表されるポリゴンの変形技法、3D点群のセグメンテーションや点群補完など、様々な技術の実装、評価を行ってきました。

また、GPGPUによる高速化や手法の改良、組み合わせによる高精度化にもトライしており、常に進化し続ける3次元処理の分野における技術課題解決をサポートしています。



### 開発例

項目	詳細情報
OS	Windows 10、Ubuntu 16.04 LTS
開発期間	3年
開発人数	2人
開発言語	C++、C#、python
関連技術	3D reconstruction Open3D 点群マッチング PointNet

# ドローン制御用自己位置推定モジュール

ドローンの利用方法は現在様々模索されていますが、その中でもここでは「巡回監視」を取り上げます。カメラ搭載ドローンを一定のコース内で巡回させ、周囲の様子を撮影・記録することが目的です。

この時、ドローンはもっぱらGPSを使用して自分の現在位置を特定し、適切に方向転換を行います。しかし、電波の届かない閉所などではGPS衛星からの信号を受信できず自己位置を特定できなくなります。

当社では、単眼カメラ(レンズモジュールが1つのカメラ)を用いて、周囲の情景からドローンの自己位置推定を行い、ドローンの自己位置に変換することを目指しました。



## GPS無しで自機の緯度・経度を推定、電波の悪い環境での機体誘導が可能に

ドローンの自己位置をGPSによらず推定するため、OpenVSLAMを用いて単眼SLAMを行う処理を実装しました。


OpenVSLAMとは、カメラに映った画像から特徴点を抽出し、その移動の具合から周囲の地図を作成すると同時に自己位置の推定を行う、Visual SLAMと呼ばれる技術のC++実装です。

お客様の要望により、自己の緯度・経度を求めることになっていたため、ArUcoと呼ばれる

技術を併用しました。これは、ARマーカーと呼ばれる特殊な模様をカメラで撮影し、そのカメラに対する角度と紐付けられた番号を推定するものです。

ARマーカーの番号と緯度・経度を対応付け、SLAMで求めた自己位置と組み合わせることで、GPSに頼ることなく自己の緯度・経度を求めることが可能となりました。

本開発では、お客様のご要望により、全体をROS2のノードとして実装しています。ROS2ノード単体では、Raspberry Pi 4上で10FPS程度で動作します。



### 開発例

項目	詳細情報
OS	Ubuntu
開発期間	2ヶ月
開発人数	3人
開発言語	C++
関連技術	OpenVSLAM ArUco ROS 2



[CC BY-SA](#)

# ロボティクス

## ～ Robotics ～

様々な分野でオートメーション化の上で欠かせない存在となってきたのが、ロボット分野です。

AI、ROS等の技術を組み合わせて最適解をご提案差し上げています。



# アームロボットを使用した強化学習

深層強化学習はカメラで撮影した画像などの複雑な情報を使って学習をし、動作を最適化する能力を持っています。

現在では、深層強化学習を利用したロボットの動作を最適化する研究が盛んに行われています。

ロボットに対して深層強化学習を適用する際に、以下のことが大きな障壁となります。

- ・学習に非常に多くの時間を要する
- ・学習中にロボットが破損する恐れがある

この解決策として、シミュレータ上にロボットを作成して学習する方法があります。ただし、現実の世界とシミュレータの世界では、取得できる情報が完全一致しているわけではないため、シミュレータ上で学習したモデルが、現実世界で上手く動作しないという問題が発生します。(ドメインシフト)

ある世界で学習したモデルを、別の世界に適応させることをドメイン適応と呼びます。当社では深層強化学習をシミュレータ上で実行し、そのモデルを現実世界のロボットに転送するドメイン適応に取り組んでいます。

Real World



Simulator World



## シミュレータで高速に学習し、実機ロボットで動かす

深層強化学習で4軸ロボットアームに目的の動作を学習させる開発を行いました。

学習はシミュレータを用いてのみ行い、現実世界のロボットによる学習は一切行いませんでした。

そのため、ドメイン適応技術を使用せずに学習を行い、その学習モデルを実機のロボットに転送すると、ドメインシフトにより目的の動作をしません。

当社では、シミュレータ上での学習時にドメイン適応技術を使用することで、実機のロボットでも目的の動作を実行するモデルを作成しました。

### 開発例



項目	詳細情報
OS	Ubuntu 18.04 LTS
開発期間	6ヶ月
開発人数	1人
開発言語	Python
使用ネットワーク	Deep Q Network
GPU	開発：Nvidia Geforce RTX 2080Ti 動作：Nvidia Geforce RTX 2080Ti
関連技術	深層強化学習 ドメイン適応



# ロボット制御支援

これまで、遠隔操作ロボットの分野では、視覚に頼った制御が大部分を占めていましたが、人間が行うさまざまな作業においては、手触りや柔らかさ、弾力性など、いわゆる「力触覚」が重要な要素となります。

この「力触覚」をロボットを通して伝えることで、遠く離れた場所であっても、重さや軽さなどの精緻な感覚をオペレータに伝えることが出来ます。

本開発では、力触覚センサを用いた遠隔2拠点間でのロボット制御システムの開発を行いました。

開発にあたって、ロボットが物に触れた際の反発力や、ロボットの関節の可動範囲を正確に制御する必要があるため、リアルタイム性の高い高速処理、通信を行うことで違和感のない遠隔制御システムを構築することが出来ました。



## 遠く離れた場所から微細な物作りを行えるシステムの実現

オペレータが操作したロボットアームの動作を、遠隔地のヒューマノイドに伝え、動作させるシステムのソフトウェア全体を開発しました。

各ロボット、センサの制御及び通信システムは、全てROS上で構築しており、ロボットやセンサ間で常に最新の状態を交換し続けることで、フィードバック遅延によるロボットアーム制御の暴れ等を無くすことに成功しました。

ヒューマノイドロボットは、汎用のロボット制御ライブラリMoveItにて制御を行っているため、仮に制御対象のボットが別のものになってしまっても、簡単なパラメータ設定だけでシステムを組み替えることが出来ます。

また、開発に当たってGazeboを使用したシミュレーション環境を構築することで実機の無い環境でも柔軟に開発を進めることが出来ました。



遠隔地からでも感触が伝わる

### 開発例

項目	詳細情報
OS	Ubuntu 16.04 LTS
開発期間	4ヶ月
開発人数	2人
開発言語	C++、python
使用フレームワーク	ROS
関連技術	Gazebo MoveIt リアルハプティクス

# データ分析

## ～ Data analysis ～

工場のIoT化やスマートフォンの登場などに伴い、様々な種類のビッグデータを取得することが可能となりました。しかし、取得したデータを有効活用するためには、データをクレンジング・解析し有用なデータする必要があります。当社では、機械学習・DeepLearningを用いて御社のデータを有効化し、さらに高度な予測を行うための手助けを行っております。

# 半導体製造装置 データ解析モジュール開発

本開発は、製造装置に紐づいた多くのデータに対し、随時発生する課題を解決するためデータの解析、可視化を行い、最終的に実システム上で動作するモジュールを提供しています。

取り扱うデータは、主に個別の装置に紐づいた温度や製造物の形状、位置などの観測データ、制御パラメータなど多岐にわたります。

それらに対し、古典的手法から近年発表された論文の手法まで、課題にあった手法をご提案し、机上検討、実データ検証、試作運用と手順を踏んで実現していきます。


## 課題に対する理解を深め、現実的な解決を

データ解析における落とし穴として、解析技術者の暴走があります。指定されたデータを解析し、目標性能を出すことに終始してしまい、別の方法で課題が解決できる可能性に目を向けなくなってしまう、というものです。

我々は「お客様が抱えている課題はどんなものか」「解決の方法は何パターン考えられるか」「より低コストで解決できる方法は何なのか」など、お客様と同じ視点で解析に取り組んでいけるよう努めています。


### ● 通常稼働時におけるセンサーデータの相関構造推定

通常稼働時のセンサーデータを学習させることで、各センサー間の相関関係を推定します。これにより、通常センサーが取りうる値の範囲や、連動するセンサーを抽出することができます。また、意図せず連動しているセンサーを特定することもでき、設計の改善などにも利用できます。




### ● システム・各センサーの異常検知

あらかじめ学習させた通常稼働時の相関構造を基に、センサーデータの異常度を計算します。システム全体の異常度や、各センサーごとの異常度、特定のセンサーグループの異常度等、様々な粒度で解析・可視化を行うことができます。



### ● 異常発生時におけるセンサーデータの因果関係推定

異常発生時における各センサーデータの変動を解析することで、センサーデータ間の因果関係を推定することができます。異常が装置内で伝搬していく流れを可視化することができ、異常の原因となったセンサーの特定に活用できます。




## 半導体製造装置 計測箇所最適化

半導体の製造工程には、ウェハと呼ばれるシリコンを円板状にカットしたものへ微細な電子回路パターンを露光する作業が含まれます。これには非常に高い精度が要求され、ウェハのナノ単位の歪みが品質に影響を与えます。

そのためこの歪みを計測/補正することが必要となりますが、ウェハ全面を計測するのはコストが高く、時間当たりの生産性を示すスループットが低下します。

この課題を解決するためウェハに生じる歪みをモデリング/推定しながら、計測箇所が可能な限り少なく済み、また歪みが正確に計測できるような計測箇所の組み合わせを最適化によって探索するという問題に取り組んでいます。



## 課題に寄り添ったソリューションのご提案

本開発で取り扱う課題は非常に専門性が高く、類似の事例もほとんどないため手法選定の段階から手探りのような状態でした。

そのような中でも、お客様へのヒアリングやディスカッションを通して要件を具体化し、課題の本質と解決手段を追求しました。

結果として、多目的最適化や組み合わせ最適化の代表手法から知名度の低い発展的手法まで様々な論文を調査し、それぞれについてアルゴリズム実装/評価を重ねることで適切な手法の選定に繋げることができました。

このような調査力と柔軟性も当社の強みの一つといえます。



### 開発例

項目	詳細情報
OS	Windows 10 Pro
開発期間	2020年10月～
開発規模	2人
開発言語	Python, C#
関連技術	<ul style="list-style-type: none"> <li>・（制約付き）組み合わせ最適化</li> <li>・焼き鈍し法</li> <li>・モデル選択</li> </ul>




# マテリアルズインフォマティクス

マテリアルズインフォマティクス（MI）とは、機械学習を材料分野に応用するという考え方です。

我々は、特にベイズ最適化をベースとした技術を用いて「狙った物性を持った新材料を少ない試作回数で合成する」ことを目標として本課題に取り組んでいます。

ベイズ最適化とはMIにおいて、「組成から物性を予測する」「狙った物性に近づける」という二つの指標から「次に試作すべき組成を提案する」といった動作を行い、一定の効果を示しますが、同時にいくつか課題もはらんでいます。

我々は、材料学を専門とするお客様のもと、ベイズ最適化の発展手法をいくつかの論文から実装し、検証、提供することでこれらの課題解決に寄与しています。



## 材料分野に限らず、製造実験全般における課題

- 狙いたい物性の間にトレードオフ関係がある

製品の示す特性といったものは多種多様で、特に材料の分野においては物性の種類は1億ともいわれています。

しかし、それらの物性は一方を狙った性質に近づけるように組成を変更すると、一方は離れていくといったトレードオフの関係が存在します。

こうなると、1つずつ物性を最適化していても、狙った物性には近づきません。

これを解決するために、ベイズ最適化を**多目的ベイズ最適化**に拡張しました。

本手法によって複数の物性を一つの指標に落とし込むことで、

「すべての物性が狙った物性にバランスよく近くなる組成の集合」を探索することができます。

- 新製品は作成に期間がかかる

製品を新規で作成する場合、受発注処理や原材料調達、スケジュール調整、運搬など時間のかかるプロセスを挟み、すぐに現物が得られるとは限りません。

材料の作成においても1回1回製造された結果を見てから次の組成を決めているようでは、待機時間が長くなってしまい、欲しい物性を得られるまで何年かかるかわかりません。

我々はこれを解決するために、**多点ベイズ最適化**を利用しました。

これは、すでに計測済みの結果から最適の可能性が高い複数の提案を得られるという手法で、一度の注文で複数の結果を得ることができます。

### 開発例

項目	詳細情報
OS	Windows
開発期間	1年以上
開発人数	1人
開発言語	python
関連技術	ベイズ最適化の拡張

これら二つを組み合わせた、

**多点多目的ベイズ最適化**も

期待された性能を示しています。

# 画像処理

## ～Image processing～

近年、DeepLearningによる画像解析が注目・活用されておりますが、従来の画像処理技術も必要不可欠です。  
当社は、長年培った画像処理の技術を活用し、DeepLearningだけでなく、画像処理を含めた多角的な視点でお客様の課題解決に臨みます。



## 電顕3次元再構築

バイオサイエンス分野において、生物組織の構造を三次元的に把握することは生命現象の理解に必要です。

生物組織の構造を三次元化するシステムは多く存在しますが、そのほとんどはデータ処理する過程で高性能なコンピュータを必要とすることと細胞構造に対する専門知識が必要であることが研究者にとって大きなボトルネックとなっていました。

これらの問題を解決することを目指し、一般的なWindows PCで機械学習を用いて簡単な操作で連続断層画像から効率よく生物組織の構造を三次元化が可能なシステムを開発しました。


## 機械学習による効率化により少データ数からの3次元構築

操作が煩雑であること同様、3次元構築に必要な学習データの多さも研究者にとってのボトルネックとなっておりました。

本システムは機械学習を用いて効率よく生物組織の構造を抽出して三次元に再構築することが可能となり、10枚程度の学習データだけでセグメンテーションを行うことが可能です。

簡単な操作で、細胞の形状を視覚的に確認することができます。

本システムにより、研究者は操作方法の理解など、研究とは無関係な作業を省くことができ、多くの時間を研究に集中することが可能となりました。



### 開発例

項目	詳細情報
OS	Windows 10
開発期間	6ヶ月
開発人数	3人
開発言語	C#.net, C++, Python
使用ネットワーク	U-net
関連技術	動的輪郭 グラフカット (Graph Cut) LiveWire OpenCV OpenGL DeepLearning

掲載内容の一部およびすべてを複製、転載または配布（電子媒体における転送含む）、印刷など、無断での使用を禁止します。

本カタログに記載の会社名及び商品名は各社の商標または登録商標となります。

本カタログの情報は2022年4月現在のものです。仕様と製品は製造・販売元が何ら責任を負うことなく予告なしに変更される場合があります。

## 株式会社コンピュータマインド



**Computermind**

東京本社

〒160-0023

東京都新宿区西新宿6丁目6-2 新宿国際ビルディング4F

☎ 03 - 6911 - 1855 (代)

✉ ai.sales@compmind.co.jp

🌐 <http://www.compmind.co.jp/>

本社

〒400-0064

山梨県甲府市下飯田1-10-8

☎ 055 - 230 - 1122 (代)